

# 1. ESPACIO MUESTRAL (S)

I

EYP1113 - I1

$$P(A) = \frac{\# A}{\# S}$$

- Para definir el espacio muestral se debe enumerar TODAS las situaciones que podrían ser un resultado del evento de interés.

- El espacio muestral varía según si se está observando 1 ó más objetos, si estos se analizan como grupo ó como individuo, o si (en el caso de ser más de 1 objeto) el suceso ocurre en todos simultáneamente (importa el orden, lo cual 'agranda' s) o si se analiza cada objeto que define el evento por separado (no importa el orden, y un evento se define sólo por el resultado en cada objeto sin importar cuál objeto tuvo el resultado).
- Lanzar 5 monedas → importa el orden → 1 experimento
- Lanzar 1 moneda 5 veces → no importa el orden → 5 experimentos
- Los eventos posibles ( $\# S$ ) se definen a partir de una 'característica' ó 'resultado' observado en 1 ó + objetos, y pueden ser equiprobables o no.

## 2. TEORÍA DE CONJUNTOS

Ley commutativa.  $A \cup B = B \cup A$   
 $A \cap B = B \cap A$

Ley asociativa.  $(A \cup B) \cup C = A \cup (B \cup C)$   
 $(AB)C = A(BC)$

Ley distributiva.  $(A \cup B) \cap C = A \cap C \cup B \cap C = AC \cup BC$   
 $(AB) \cup C = (A \cup C) \cap (B \cup C)$

Ley de Morgan.  $E_1 \cup E_2 \cup \dots \cup E_n = \bar{E}_1 \cap \bar{E}_2 \cap \dots \cap \bar{E}_n$   
 $\bar{E}_1 \cdot \bar{E}_2 \cdot \bar{E}_n = \bar{E}_1 \cup \bar{E}_2 \cup \dots \cup \bar{E}_n$

## 3. MATEMÁTICA DE LA PROBABILIDAD

Axiomas de probabilidades:  $P(E) \geq 0$   
 $P(S) = 1$

Para eventos mutuamente excluyentes:  $P(E_1 \cup E_2) = P(E_1) + P(E_2)$

Propiedades de los axiomas. 1.  $\forall E \subseteq S$ :  
 $P(E) = 1 - P(\bar{E})$   
 $P(\bar{E}) = 1 - P(E)$

2.  $\forall E_1, E_2 \subseteq S$ :  
 $P(E_1 \cup E_2) = P[E_1 \cup (E_2 \cap \bar{E}_1)]$   
 $= P(E_1) + P(E_2 \cap \bar{E}_1)$

Ley Aditiva.  $P(E_1 \cup E_2 \cup \dots \cup E_n) = 1 - P(\bar{E}_1 \cup \bar{E}_2 \cup \dots \cup \bar{E}_n)$   
 $= 1 - P(\bar{E}_1 \cap \bar{E}_2 \cap \dots \cap \bar{E}_n)$

Ley Multiplicativa.  $P(E_1 \cap E_2 \cap E_3) = P(E_1 | E_2 \cap E_3) \cdot P(E_3 | E_2) \cdot P(E_2)$   
 $= P(E_1 | E_2 \cap E_3) \cdot P(E_2 | E_3) \cdot P(E_3)$

\* Puede elegirse  $E_1, E_2, E_3$  en cualquier orden y da el mismo resultado.

## 4. CÓMO 'CONTAR'

→ Herramientas para establecer la cardinalidad # de un conjunto (La cantidad de eventos que contiene).

### • Principio de multiplicación.

Si el 'evento de interés' se define a partir de  $K$  experimentos de tamaños muestrales  $n_1, n_2, \dots, n_K$ , para el espacio muestral de este se cumple:

$$\#S = n_1 \cdot n_2 \cdots n_K$$

### • Herramientas para identificar los valores $n_1, \dots, n_K$ :

#### • Permutación. - $n$ objetos $\in C = \{c_1, c_2, \dots, c_m\}$

- Se tiene  $r$  'cupos' para situar estos objetos

- Los objetos son 'individuales', es decir, es relevante el orden en que se los elija (qué 'puesto' va a ocupar el objeto  $i$ )

(a) con reemplazo. Los  $n$  elementos se encuentran disponibles en cada 'muestreo' (elección de candidato para un puesto), es decir, el elemento  $c_i$  puede repetirse.

$$\# = n^r$$

(b) sin reemplazo. Si un elemento es elegido para un 'puesto', no puede volver a ser elegido y 'desaparece' del conjunto  $C$  para el siguiente muestreo.

$$\# = n \cdot (n-1) \cdot (n-2) \cdots (n-r+1) = \boxed{nPr} \text{ en la calculadora}$$

#### • Combinación. - $n$ objetos $\in C = \{c_1, c_2, c_m\}$

- Se quiere formar 'grupos' de tamaño  $r$  (sin reemplazo, los elementos no pueden repetirse en el grupo) en que no importa qué 'puesto' tome cada elemento.

$$\# = \binom{n}{r} = \frac{n!}{r!(n-r)!} = \boxed{mCr} \text{ en la calculadora}$$

#### • Ordenamiento multinomial. - $n$ objetos $\in C = \{c_1, c_2, \dots, c_m\}$

- Se quiere formar  $K$  'grupos' (sin orden de entrada, sin reemplazo) de tamaños  $n_1, \dots, n_K$  donde  $\sum_{i=1}^K n_i = n$

$$\# = \binom{n}{n_1 n_2 \cdots n_K} = \frac{n!}{n_1! \cdot n_2! \cdots n_K!}$$

## 5. DEPENDENCIA E INDEPENDENCIA DE EVENTOS

### • Probabilidad condicional.

Cuando 2 eventos son dependientes y se tiene la certeza de que uno ocurrió, se puede tomar ~~el espacio~~ el evento ocurrido como espacio muestral.

$$P(E_1|E_2) = \frac{P(E_1 \cap E_2)}{P(E_2)}$$

$P(E_2)$  → El espacio muestral se reduce a aquellos puntos muestrales en que ocurre  $E_2$ .

### • Propiedades de la condicionalidad.

$$P(E_1S) = P(E)$$

$$P(\bar{E}_1|E_2) = \frac{P(\bar{E}_1 \cap E_2)}{P(E_2)} = 1 - P(E_1|E_2)$$

### • Independencia estadística.

Dos eventos son estadísticamente independientes si:

$P(E_1|E_2) = P(E_1)$  ó  $P(E_2|E_1) = P(E_2)$  → La ocurrencia o no de  $E_2$  no cambia al reducir el espacio muestral.

$$\rightarrow P(E_1 \cap E_2) = P(E_1) \cdot P(E_2)$$

### • Eventos mutuamente independientes.

Se tiene n eventos  $E_1, E_2, \dots, E_n$ . Si cualquier subconjunto de ellos cumple

con  $P(E_a \cap \dots \cap E_m) = P(E_a) \cdots P(E_m)$  se dice que son mutuamente independientes.

→ Es condición necesaria pero no suficiente que exista independencia estadística en cada 'par' de eventos.

## 6. OTROS TEOREMAS

### • Teorema de Probabilidades Totales.


- n eventos  $E_1, \dots, E_n$  colectivamente exhaustivos y mutuamente excluyentes.

→ La probabilidad de un evento cualquiera A es:

$$P(A) = \sum_{i=1}^n P(A|E_i) \cdot P(E_i)$$

### • Teorema de Bayes.

- n eventos  $E_1, \dots, E_n$  colectivamente exhaustivos y mutuamente excluyentes.



$$P(E_j|A) = \frac{P(A|E_j) \cdot P(E_j)}{\sum_{i=1}^n P(A|E_i) \cdot P(E_i)}$$

## 7. VARIABLES ALEATORIAS

VARIABLE ALEATORIA:  $X: S \rightarrow \mathbb{R}$

Toma un EVENTO del espacio muestral y le asigna un número real.

Los valores que  $X$  puede tomar se conocen como el SOPORTE DE  $X, \Theta_X$ .

Los eventos se representan según el valor que queremos que tome  $X$ :

$$X = x$$

$$X < x$$

$$X > x$$


$$x_1 > X > x_2$$

minúscula el valor  
que queremos q tome.  
mayúscula es la variable.

El valor que tome dentro de los que permite  $\Theta_X$  es ALEATORIO,

DISTRIBUCION DE PROBABILIDAD: Es la 'regla' o transformación que

'mapea' la variable



FUNCION DE DISTRIBUCION DE PROBABILIDAD ACUMULADA: Para CUALQUIER

variable aleatoria,  $F_X(x)$  entrega la PROBABILIDAD de que  $X$  tome (dentro de su soporte) un valor menor o igual a  $x$ .

$$F_X(x) = P(X \leq x)$$

$$X, \Theta_X$$

DISCRETA

$$P_X(x) = P(X = x)$$

$$P(a < X \leq b) = \sum_{x_i \leq b} P_X(x_i) - \sum_{x_i < a} P_X(x_i)$$

$$F_X(x) = \sum_{x_i \leq x} P_X(x_i)$$

\*  $P_X(x)$ : Función de distribución de probabilidad

CONTINUA [ $P(X < x) = P(X \leq x)$ ]

$$f_X(x) = 0 \quad \int_{-\infty}^{\infty} f_X(x) dx = 1$$

$$\int_a^b f_X(x) dx = P(a < X \leq b)$$

$$f_X(x) = \frac{d}{dx} F_X(x)$$

$$P(a < X \leq b) = \int_{-\infty}^b f_X(x) dx - \int_{-\infty}^a f_X(x) dx$$

$$F_X(x) = \int_{-\infty}^x f_X(t) dt$$

En ambos casos...

$$F_X(x) = P(X \leq x)$$

$$F_X(-\infty) = 0$$

$$F_X(\infty) = 1$$

$F_X(x)$  es continua por la derecha

\*  $F_X(x)$  es la función de distribución de probabilidad acumulada

## 8. MEDIDAS DESCRIPTIVAS

VALOR MEDIO / VALOR ESPERADO  $\mu_x = \text{ESPERANZA } E(X)$

→ Es el 'promedio ponderado' del soporte de la variable,  $\Theta_x$

$$\mu_x = E(X) = \begin{cases} \sum_{x \in \Theta_x} x \cdot p_x(x) \\ \int_{-\infty}^{\infty} x \cdot f_x(x) dx \end{cases} * \text{ Existe si } E(|X|) < \infty$$

→ Muchas veces necesitamos la esperanza de  $X^2, X^3$ , u otras funciones de  $X$ .  $E[g(X)] = \sum / \int g(x) \cdot p_x/f_x(x)$

→ Pero, la mayoría de las veces es útil

calcular potencias de  $X$  con la

FUNCIÓN GENERADORA DE MOMENTOS  $M_x$

(Función específica para cada variable aleatoria)

$$M_x(t) = E(e^{tx}) = \begin{cases} \sum_{x \in \Theta_x} e^{tx} p_x(x) \\ \int_{-\infty}^{\infty} e^{tx} f_x(x) dx \end{cases}$$

Una vez calculada  $M_x(t)$ , puedo derivarla  $n$  veces y evaluar en  $t=0$ ; esto me entrega  $E(X^n)$ .

MEDIANA:  $x_{\text{med}} = x_{0,5}$

$$F_x(x_{\text{med}}) = 1/2$$

PERCENTIL  $p \times 100\% : x_p$

$x_p$  es el valor del dato que se encuentra en el percentil  $p \times 100\%$ .

$$F_x(x_p) = p$$

VARIANZA:  $\sigma_x^2$

$$\sigma_x^2 = \text{Var}(X) = E[(X - \mu_x)^2] = E[X^2 - 2X\mu_x + \mu_x^2] = E(X^2) - 2\mu_x E(X) + \mu_x^2 = E(X^2) - E(X)^2 = M_x''(0) - [M'_x(0)]^2$$

DESVIACIÓN ESTÁNDAR:  $\sigma_x = \sqrt{\sigma_x^2} = \sqrt{\text{Var}(X)} = \sqrt{M_x''(0) - [M'_x(0)]^2}$

COEFICIENTE DE VARIACIÓN:  $\delta_x = \frac{\sigma_x}{\mu_x}$

IQR:  $IQR = x_{0,75} - x_{0,25}$

$$\text{ASIMETRÍA (skewness)} = E[(X - \mu_x)^3] = E[X^3 - 3X^2\mu_x + 3X\mu_x^2 - \mu_x^3]$$

$$= E(X^3) - \mu_x E(X^2) \cdot 3 + 3\mu_x^2 E(X) - \mu_x^3$$

$$= E(X^3) - 3E(X) \cdot E(X^2) + 3[E(X)]^2 - [E(X)]^3$$

$$= E(X^3) + 3E(X)[E(X)^2 - E(X^2)]$$

$$= E(X^3) - 3E(X) \cdot \text{Var}(X)$$

$$= M_x'''(0) - 3M_x'(0)[M_x''(0) - (M_x'(0))^2]$$

COEFICIENTE DE ASIMETRÍA:  $\theta_x$

$$\theta_x = \frac{E[(X - \mu_x)^3]}{\sigma_x^3}$$

$$= \frac{E(X^3) - 3E(X)\text{Var}(X)}{[\text{Var}(X)]^{3/2}}$$

$$= \frac{M_x'''(0) - 3M_x'(0)[M_x''(0) - (M_x'(0))^2]}{[M_x''(0) - (M_x'(0))^2]^{3/2}}$$

$$\text{KURTOSIS} = E[(X - \mu_x)^4] = E[X^4 + 4X^3\mu_x + 6X^2\mu_x^2 + 4X\mu_x^3 + \mu_x^4]$$

$$= E(X^4) + 4E(X^3)E(X) + 6E(X^2)[E(X)]^2 - 4[E(X)]^4 + E(X)^4$$

$$= E(X^4) + E(X)[-4E(X^3) + 6E(X)E(X^2) - 3E(X)^3]$$

$$= M_x^{(4)}(0) + M_x'(0)[6M_x''(0) \cdot M''(0) - 4M_x'''(0) - 3(M_x'(0))^3]$$

$$\text{COEFICIENTE DE KURTOSIS : } K_x = \frac{E[(X - \mu_x)^4]}{\sigma_x^4} - 3$$

$$= \frac{M_x^{(4)}(0) + M_x'(0)[6M_x''(0) \cdot M''(0) - 4M_x'''(0) - 3(M_x'(0))^3]}{[M''(0) - (M_x'(0))^2]^2} - 3$$

# DISTRIBUCIONES DE PROBABILIDAD

## 1. DISTRIBUCION NORMAL ( $\mu, \sigma$ )

• Continua


•  $\Theta_x : -\infty < x < \infty$

$-\infty < \mu < \infty$

$0 < \sigma < \infty$

$$f_x(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot \exp\left(-\frac{1}{2} \left(\frac{x-\mu}{\sigma}\right)^2\right)$$

• Es simétrica:



• Función generadora de momentos:

$$\int_{-\infty}^{\infty} e^{tx} \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot \exp\left[-\frac{1}{2} \left(\frac{x-\mu}{\sigma}\right)^2\right] dx$$

$$= \exp\left[\mu t + \frac{\sigma^2 t^2}{2}\right]$$

$$P(X \leq \mu) = P(X > \mu) = 1/2$$

$$P(X \leq \mu+a) = P(X > \mu-a) = 1 - P(X \leq \mu-a)$$

$$P(X \leq \mu-a) = P(X > \mu+a) = 1 - P(X \leq \mu+a)$$

• Función de distribución de probabilidad acumulada:  $F_x(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot \exp\left[-\frac{1}{2} \left(\frac{t-\mu}{\sigma}\right)^2\right] dt$

~ Es una integral imposible de calcular.  
∴  $F_x(x) = P(X \leq x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$  →  $\Phi(s)$  es la función de distribución de probabilidad acumulada de una normal (0,1).

## DISTRIBUCION NORMAL ESTANDAR.

$S \sim \text{normal-estandar} \iff S \sim \text{Normal}(0,1)$

$$f_s(s) = \frac{1}{\sqrt{2\pi}} e^{-s^2/2} \quad ; \quad \int_{-\infty}^s \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = F_s(s) = \Phi(s) = P(S \leq s)$$

$$P(S \leq -a) = P(S \geq a) = 1 - \Phi(a)$$

$$P(S \leq a) = P(S \geq -a) = \Phi(a)$$

$$P(-a \leq S \leq b) = \Phi(b) - \Phi(-a)$$

$$= \Phi(b) - (1 - \Phi(a))$$

$$S_p = \Phi^{-1}(p)$$

$$\bullet \text{ Si: } P(S \leq s) = a$$

$$s = \Phi^{-1}(a)$$


$$\bullet \text{ Si: } P(S > s) = a$$

$$P(S \leq s) = 1 - a$$

$$s = \Phi^{-1}(1 - a)$$


$$\bullet \text{ Si: } P(-s \leq S \leq s) = a$$

$$P(S \leq s) = 0,5 + \frac{a}{2} \quad s = \Phi^{-1}(0,5 + \frac{a}{2})$$



# Distribución log-normal

• Continua



$$f_x(x) = \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{Sx} \cdot \exp\left[-\frac{1}{2}\left(\frac{\ln x - \lambda}{S}\right)^2\right]$$

$x > 0$

$$\begin{aligned} \lambda &= E(\ln x) \\ S &= \sqrt{\text{Var}(\ln x)} \end{aligned}$$

- Si  $X \sim \text{log-normal}(\lambda, S)$ , el logaritmo de  $X$  distribuye normal.

- $\ln X \sim \text{Normal}(\lambda, S)$
- $Y = \ln X$ ;  $X = e^Y$

$$\begin{aligned} F_X(x) &= \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{Sx} \cdot \exp\left[-\frac{1}{2}\left(\frac{\ln x - \lambda}{S}\right)^2\right] dx \quad / \quad \begin{aligned} u &= \ln x \\ \frac{du}{dx} &= \frac{1}{x} \end{aligned} \\ &= \int_{-\infty}^{\ln(x)} \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{S} \exp\left[-\frac{1}{2}\left(\frac{u - \lambda}{S}\right)^2\right] du = \Phi\left(\frac{\ln(x) - \lambda}{S}\right) \\ F_X(x) &= \Phi\left(\frac{\ln(x) - \lambda}{S}\right) \end{aligned}$$

$$\begin{aligned} M_X(x) &= \int_{-\infty}^{\infty} e^{tx} \cdot \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{Sx} \cdot \exp\left[-\frac{1}{2}\left(\frac{\ln x - \lambda}{S}\right)^2\right] dx \\ &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{S} \exp\left[t\ln x - \frac{1}{2}\left(\frac{\ln x - \lambda}{S}\right)^2\right] dx \quad \rightsquigarrow X^{(s)} = e^s \ln x \end{aligned}$$

$$\rightsquigarrow \frac{d^{(s)}}{dt^{(s)}} M_X(t) \Big|_{t=0} = \exp\left[s\lambda + \frac{S^2 s^2}{2}\right]$$

$$\begin{aligned} F(X_m) &= \frac{1}{2} \\ \underbrace{\Phi\left(\frac{\ln(X_m) - \lambda}{S}\right)}_0 &= \frac{1}{2} \end{aligned}$$

$$\ln(X_m) - \lambda = 0$$

$$\ln(X_m) = \lambda$$

$$X_m = e^\lambda \quad \text{mediana} = e^\lambda$$

$$E(X) = \int_0^\infty \frac{x}{\sqrt{2\pi}} \cdot \frac{1}{Sx} \exp\left[-\frac{1}{2}\left(\frac{\log x - \lambda}{S}\right)^2\right] dx$$

$y = \ln x$   
 $dy = \frac{dx}{x}$   
 $x = e^y$

$x \rightarrow 0 ; y \rightarrow -\infty$   
 $x \rightarrow \infty ; y \rightarrow \infty$

$$= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \cdot \frac{e^y}{S} \cdot \exp\left[-\frac{1}{2}\left(\frac{y - \lambda}{S}\right)^2\right] dy$$

$$= e^{\lambda + \frac{1}{2}S^2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{S} \cdot \exp\left[-\frac{1}{2S^2}\left(y - (\lambda + S^2)\right)^2\right] dy$$

Normal( $\lambda + S^2, S$ )

$$\begin{aligned} \mu_x &= E(X) = e^{\lambda + \frac{1}{2}S^2} \\ \sigma_x^2 &= \mu_x^2 (e^{S^2} - 1) \end{aligned}$$

teniendo  $\mu_x$  y  $\sigma_x^2$  se pueden  
despejar  $\lambda$  y  $S$

### • Obteniendo los parámetros.

$$\text{con } \mu_x \rightarrow \lambda = \ln \mu_x - \frac{1}{2}S^2$$

$$dx = \frac{\sigma_x}{\mu_x} = \frac{\mu_x^2 (e^{S^2} - 1)}{\mu_x} = e^{S^2} - 1 \rightarrow S^2 = \ln(1 + dx^2)$$

$$S = \sqrt{\ln(1 + dx^2)}$$

$$\text{• Si } dx \leq 0,3 \rightarrow S \approx dx$$

# Bernoulli

- Experimento con 2 resultados posibles: éxito ó fracaso
- Hay una probabilidad  $p$  de éxito ;  $p \in (0,1)$

$X \sim \text{Bernoulli}(p)$ :

$$P_X(x) = P(X=x) = p^x(1-p)^{1-x} ; \Theta x = 0,1$$

éxito  $\rightarrow X=1 \rightarrow p = P(\text{éxito}) = P(X=1)$  / fracaso:  $X=0$

→ si tengo una sucesión de eventos Bernoulli:

## Distribución Binomial

• Discreta

$X \sim \text{Binomial}(n,p)$

$X$  = cantidad de éxitos en  $n$  ensayos.

$$P(X=x) = P_X(x) = \binom{n}{x} p^x (1-p)^{n-x} ; \Theta x = 0,1,2,\dots,n$$

$$F_X(x) = \sum_{i=0}^{\lfloor x \rfloor} \binom{n}{i} p^i (1-p)^{n-i} ; 0 \leq x \leq n$$

$$\begin{aligned} M_X(t) &= E(e^{xt}) = \sum_{x=0}^n e^{xt} \binom{n}{x} p^x (1-p)^{n-x} \\ &= \sum_{x=0}^n \binom{n}{x} (pet)^x (1-p)^{n-x} = (pet + (1-p))^n \end{aligned}$$

a = pet  
b = 1 - p  
por propiedad

$$M_X(t) = [pet + (1-p)]^n$$

$$M_X'(0) = \left. pet \cdot n [pet + (1-p)]^{n-1} \right|_{t=0} = pn [1 + (1-p)]^{n-1} = pn$$

$$E(X) = \mu_X = n \cdot p$$

$$M_X''(0) = E(X^2) = np[(n-1)p + 1]$$

$$\text{var}(X) = E(X^2) - E(X)^2 = n^2 p^2 - np[(n-1)p + 1] = np^2 - np^2 + np^2 - np$$

$$\text{var}(X) = np(1-p)$$

# Distribución geométrica

• Discreta

$X \sim \text{Geométrica}(p)$

$X = \text{nº de ensayos Bernoulli que pasan hasta el 1º éxito}$   
(o cuántos faltan para el siguiente).

→ También se conoce como "tiempo de retorno" a su esperanza

$$\bar{T} = E(X)$$

$$E(X) = \sum_{x=1}^{\infty} x p(1-p)^{x-1} = \frac{1}{p}$$

Probabilidad de que falten  $x$  experimentos o periodos para el siguiente éxito:  $P_X(x) = p(1-p)^{x-1}$ ;  $x = 1, 2, \dots$

$$F_X(x) = \sum_{k=1}^{[x]} p(1-p)^{k-1} = 1 - (1-p)^{[x]}$$

Probabilidad de que no hayan éxitos en  $x-1$  ensayos

→ La distribución geométrica no tiene memoria

$$P(X=a+b | X > a) = P(X=b)$$

$$M_X(t) = \frac{p}{1 - (1-p)e^t}$$

# Distribución binomial negativa

• Discreta

$X \sim \text{Binomial-negativa}(r, p)$

$X = \text{Número de ensayos Bernoulli que transcurren hasta observar } r \text{ éxitos.}$

$$P(X=x) = \binom{x-1}{r-1} p^r (1-p)^{x-r}; \quad x = r, r+1, r+2, \dots$$

→ Esto implica que hay  $r-1$  éxitos a lo largo de  $x-1$  ensayos.

$$P[\text{Binomial negativa } (r, p) = x] = P[\text{Binomial } (r-1, p) = x-1]$$

$$F_X(x) = \sum_{k=r}^{[x]} \binom{k-1}{r-1} p^r (1-p)^{k-r}$$

$$M_X(t) = \left( \frac{p}{1 - (1-p)e^t} \right)^r$$

# Poisson

$$X \sim \text{Poisson}(\nu t)$$

$$\lambda = \nu t$$

↳ Donde  $t$  es la "unidad" y  $\nu$  es eventos x unidad.

Intuición: Si se divide el tiempo en porciones diferenciales, en cada porción hay una variable Bernoulli (Pasa o no pasa) ( $n \rightarrow \infty$ )

$$F_X(x) = \sum_{k=1}^{[x]} \frac{e^{-\lambda} \lambda^k}{k!}$$

$$M_X(t) = E(e^{tx}) = \sum_{x=0}^{\infty} e^{tx} \frac{e^{-\lambda} \lambda^x}{x!}$$

$$= e^{-\lambda} \sum_{x=0}^{\infty} \frac{(e^t \cdot \lambda)^x}{x!} * \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = \exp(\lambda)$$

$$= e^{-\lambda} \exp(e^t \cdot \lambda) = e^{\lambda(e^t - 1)}$$

$$M_X(t) = e^{\lambda(e^t - 1)}$$

## Distribución exponencial

Si  $X \sim \text{Poisson}(\lambda)$ ;  $T_1 \sim \text{exponencial}(\nu)$ :

$$P(T_1 > t) = P(X=0) = e^{-\nu t}$$

$$\therefore F_{T_1}(t) = P(t > T_1) = 1 - e^{-\nu t}$$

$$f_{T_1}(t) = \nu e^{-\nu t}; \Theta_x = X \geq 0$$

↳ No tiene memoria:  $P(T_1 > t+s) | T_1 > s) = P(T_1 > t)$

- Discreta

- Describe eventos con una "tasa de ocurrencia"
  - ↳ Se lleva el tiempo a una "unidad" (día, hora, s, etc.)

$X$  = número de eventos x unidad de tiempo.

$$P_X(x) = P(X=x) = \frac{e^{-\lambda} \lambda^x}{x!}; \Theta_X = 0, 1, 2, \dots$$

\*  $\lambda = \nu t \rightarrow t$  es el intervalo  $(0, t)$  (su duración) en que se analiza la ocurrencia del evento

→  $\nu$  es la ocurrencia media del evento x unidad de tiempo

↳ entonces,  $\lambda$  es la ocurrencia media del evento en cualquier intervalo del largo de  $(0, t)$ .

$$E(X_t) = \nu t = \lambda$$

Propiedad útil:

$$e^\lambda = \sum_{x=0}^{\infty} \frac{\lambda^x}{x!}$$

$$\rightarrow \sum_{x=0}^{\infty} \frac{e^{-\lambda} \lambda^x}{x!} = 1$$

- Continua
- Describe el tiempo entre eventos Poisson, o el tiempo que falta para el sgte. evento en cualquier instante.

$$M_{T_1}(t) = E(e^{xt}) = \int_{-\infty}^{\infty} e^{xt} ve^{-vx} dx = v \int_0^{\infty} e^{x(t-v)} dx$$

$$= v \left[ \frac{1}{t-v} e^{x(t-v)} \right]_{x=0}^{x=\infty}$$

$$E(X) = M_{T_1}'(0) = \frac{-v}{(v-t)^2} \Big|_{t=0} = \frac{1}{v}$$

$$E(T_1) = \frac{1}{v}$$

$$M_{T_1}''(0) = \frac{v \cdot 2(v-t)}{(v-t)^4} \Big|_{t=0} = \frac{2}{v^2}$$

$$\text{Var}(T_1) = \left(\frac{1}{v}\right)^2 - \frac{2}{v^2}$$

$$\text{Var}(T_1) = \frac{1}{v^2}$$

si  $t < v$  :  $M_{T_1}(t) = \frac{v}{v-t}$   
 (siempre será el caso ya que  $M$  se evalúa en  $0$  para usarla)

$$F_x(x) = \int_{-\infty}^x f_x(x) = \int_0^x ve^{-vx} dx \quad ; \quad x > 0$$

$$= v \int_0^x e^{-vx} dx = v \left[ \left(-\frac{1}{v}\right) e^{-vx} \right]_{x=0}^{x=x}$$

$$= -e^{-vx} + 1$$

## Distribución gamma

• continua

$X \sim \text{Gamma}(k, v)$

$X$  = Tiempo que pasa desde el 'presente' hasta el  $k$ -ésimo evento Poisson.

$$f_x(x) = \frac{v^k}{\Gamma(k)} \cdot x^{k-1} \cdot e^{-vx} \quad ; \quad \Theta_X = x > 0$$

$$* T(k) = \int_0^{\infty} u^{k-1} e^{-u} du$$

Si  $X_t \sim \text{Poisson}(vt)$ :

$$P(X > t) = P(X_t \leq k-1) = \sum_{x=0}^{k-1} \frac{(vt)^x e^{-vt}}{x!}$$

$$\therefore F_x(x) = 1 - \sum_{x=0}^{k-1} \frac{(vt)^x e^{-vt}}{x!}$$

$$M_x(t) = \int_0^{\infty} e^{tx} \frac{v^k}{\Gamma(k)} \cdot x^{k-1} \cdot e^{-vx} dx = \frac{v^k}{(v-t)^k} \int_0^{\infty} \frac{(v-t)^k}{\Gamma(k)} x^{k-1} e^{-(v-t)x} dx$$

Gamma( $k, v-t$ )

$$M_x(t) = \frac{v^k}{(v-t)^k}$$

$$M_x'(0) = \frac{v^k (-1)(k-1) (v-t)^{k-2}}{[(v-t)^k]^2} \Big|_{t=0} = \frac{-v^k \cdot k \cdot v^{k-1}}{v^{2k}} = \frac{k}{v} \quad E(X) = \frac{k}{v}$$

$$M_x''(0) = \frac{k^2}{v^2} + \frac{k}{v^2} \quad \text{Var}(X) = \frac{k}{v^2}$$

# Distribución Hipergeométrica

• Discreta

$X \sim \text{Hipergeométrica}(N, m, n) \rightarrow$  Donde  $N = \text{tamaño de muestra}$

$X = \text{cantidad de los elementos tomados que pertenecen a la categoría.}$

- $m = \text{cantidad de elementos de la muestra que pertenecen a una categoría}$
- $n = \text{cantidad de elementos que se toma de la muestra}$

$$P_x(x) = \frac{\binom{m}{x} \binom{N-m}{n-x}}{\binom{N}{n}}$$

$$F_x(x) = \sum_{i=0}^{[x]} \frac{\binom{m}{i} \binom{N-m}{n-i}}{\binom{N}{n}}$$

$$E(X) = n \frac{m}{N}$$

$$\text{Var}(X) = \left(\frac{N-n}{N-1}\right) m \frac{m}{N} \left(1 - \frac{m}{N}\right)$$

# Distribución Beta

• continua

$X \sim \text{Beta}(q, r)$

Si no se especifican valores para  $a$  y  $b$ :  $a=0$ ,  $b=1$ ,  $\theta_x = 0.1$

→  $X$  distribuye valores entre  $a$  y  $b$  con proporciones entregadas por  $q$ (parámetro de forma) y  $r$ (parámetro de forma 2)

⇒ Para  $a=0$ ,  $b=1$ :  $f_x(x) = \frac{1}{B(q, r)} (x^{q-1} (1-x)^{r-1})$

# Distribución Weibull (AKA 'LA WEIBULL')

• continua

$T \sim \text{Weibull}(\eta, \beta) \rightarrow$  Donde  $\beta = \text{Parámetro de forma}$

$\eta = \text{Parámetro de escala}$

- $\beta < 1$ : Tasa de fallos decrece con el tiempo
- $\beta = 1$ : Tasa de fallos C.R.
- $\beta > 1$ : Tasa de fallos crece con el tiempo

$$f_T(t) = \frac{\beta}{\eta} \left(\frac{t}{\eta}\right)^{\beta-1} \exp\left[-\left(\frac{t}{\eta}\right)^\beta\right] ; t > 0$$

• Importante: Saber integrar / derivar la weibull

$$F_T(t) = \int_0^t \frac{\beta}{\eta} \left(\frac{x}{\eta}\right)^{\beta-1} \exp\left[-\left(\frac{x}{\eta}\right)^\beta\right] dx. \quad u = \left(\frac{x}{\eta}\right)^\beta \quad du = \beta \left(\frac{x}{\eta}\right)^{\beta-1} \cdot \frac{1}{\eta} dx$$

$$= \int_0^t -\exp[u] du = -\exp\left[-\left(\frac{x}{\eta}\right)^\beta\right] \Big|_{x=0}^{x=t} = -\exp\left[-\left(\frac{t}{\eta}\right)^\beta\right] + 1$$

$$F_T(t) = 1 - \exp\left[-\left(\frac{t}{\eta}\right)^\beta\right]$$

$$f_T(t) = \frac{dF_T(t)}{dt} = - \left[ \frac{d}{dt} \left( -\exp\left[-\left(\frac{t}{\eta}\right)^\beta\right] \right) \right] = \frac{\beta}{\eta} \left(\frac{t}{\eta}\right)^{\beta-1} \exp\left[-\left(\frac{t}{\eta}\right)^\beta\right]$$

$$E(T) = \int_0^\infty t f_T(t) dt = \int_0^\infty t \frac{\beta}{\eta} \left(\frac{t}{\eta}\right)^{\beta-1} \exp\left[-\left(\frac{t}{\eta}\right)^\beta\right] dt \quad u = \left(\frac{t}{\eta}\right)^\beta \quad du = \frac{\beta}{\eta} \left(\frac{t}{\eta}\right)^{\beta-1} dt$$

$$* T(n) = \int_0^\infty u^{n-1} e^{-u} du \quad T(a+1) = a T(a)$$

$$= \int_0^\infty t \exp(-u) du$$

$$= \int_0^\infty u^{1/\beta} \eta \exp(-u) du = \eta T(1/\beta + 1) = \frac{\eta}{\beta} T(1/\beta)$$

$$E(T) = \frac{\eta}{\beta} T(1/\beta)$$

$$M_T(u) = \int_0^\infty \exp(ut) \frac{\beta}{\eta} \left(\frac{t}{\eta}\right)^{\beta-1} \exp\left[-\left(\frac{t}{\eta}\right)^\beta\right] dt = \text{imposible}$$

• Para obtener los parámetros se despeja un sistema de ecuaciones con los percentiles:

$$\ln(t_p) = \ln(\eta) + \frac{1}{\beta} \Phi_{\text{weibull}}^{-1}(p)$$

$$\Phi_{\text{weibull}}^{-1}(p) = \ln[-\ln(1-p)]$$

# Distribución logística

• continua

$$F_Y(y) = \frac{\exp(\frac{y-\mu}{\sigma})}{1 + \exp(\frac{y-\mu}{\sigma})}$$

$$f_Y(y) = \frac{1}{\sigma} \frac{\exp(\frac{y-\mu}{\sigma})}{[1 + \exp(\frac{y-\mu}{\sigma})]^2}$$

- Parámetros  $\mu$  y  $\sigma$  se despejan de los percentiles

## log - logística

$$F_T(t) = F_Y(\ln(t)) \quad f_T(t) = \frac{1}{t} f_Y(\ln(t))$$

- $\sigma$  y  $\mu$  se despejan de los percentiles.

# Distribución T-Student

• continua

→ T se parece a una distribución normal a medida que el parámetro  $v$  crece

Para  $v > 30$   $T \approx \text{Normal}(\mu_T, \sigma_T)$  y se puede usar la tabla.  
 $v$  = grados de libertad

→ Si  $X_1, \dots, X_n \sim \text{Normal}(\mu, \sigma)$

$$\bar{X}_n = \frac{\sum X_i}{n}, \quad T = \frac{\bar{X}_n - \mu}{S_n / \sqrt{n}} \quad \rightarrow v = n-1$$

# Distribución de Pearson (ó Chi cuadrado)

• continua

• no está en el formulario.

$$X_k^2 = Z_1^2 + \dots + Z_k^2 \sim \text{Chi-cuadrado}(k)$$

donde  $Z_i \sim \text{Normal}(0, 1)$

$$f_{X_k^2}(x) = \frac{1}{2^{k/2} \Gamma(k/2)} x^{(k/2)-1} e^{-x/2} \quad ; \quad x > 0$$

$$0 \quad ; \quad x \leq 0$$

# MÚLTIPLES VARIABLES ALEATORIAS

~ Caso bidimensional:  $F_{xy}(x,y) = P(X \leq x, Y \leq y)$

## CASO DISCRETO.

$$F_{xy}(x,y) = \sum_{x_i \leq x} \sum_{y_j \leq y} P_{xy}(x_i, y_j) \quad f_{xy}(x,y) = \frac{\partial^2}{\partial x \partial y} F_{xy}(x,y)$$

Distribuciones marginales:

$$P_x(x) = \sum_{y \in \Theta_y} P_{xy}(x, y) = \sum_{y \in \Theta_y} P_{x|y=x}(x) \cdot P_y(y)$$

$$P_y(y) = \sum_{x \in \Theta_x} P_{xy}(x, y) = \sum_{x \in \Theta_x} P_{y|x=x}(y) \cdot P_x(x)$$

APLICACION  
 $\Theta_x = a, b$   
 $\Theta_y = c, d, e$

		y		
		c	d	e
x	a	$p_1$	$p_2$	$p_3$
	b	$p_4$	$p_5$	$p_6$

$$P_x(x) = \begin{cases} p_1 + p_2 + p_3, & x=a \\ p_4 + p_5 + p_6, & x=b \end{cases}$$

$$\sum_{i=1}^6 p_i = 1$$

Distribución condicional:

$$P_{x|y=x}(x) = P_{xy}(x,y)$$

$$P_{y|x=x}(y) = \frac{P_{xy}(x,y)}{P_x(x)}$$

ya evaluadas en  $y=y$  ó  $x=x$

~ Si no se tiene la conjunta se puede despejar de la condicional.

$$P_{x|y=c} = \begin{cases} \frac{p_1}{p_1+p_4}, & x=a \\ \frac{p_4}{p_1+p_4}, & x=b \end{cases}$$

$$\Theta_{xy} = \{(a,c), (a,d), (a,e), (b,c), (b,d), (b,e)\}$$

$$P_y(y) = \begin{cases} p_1 + p_4 & ; y=c \\ p_2 + p_5 & ; y=d \\ p_3 + p_6 & ; y=e \end{cases}$$

CASO CONTINUO.  $F_{xy}(x,y) = \int_{-\infty}^x \int_{-\infty}^y f_{xy}(x,y) dx dy$

$$f_{x|y=y}(x) = \frac{f_{xy}(x,y)}{f_y(y)}$$

$$f_{y|x=x}(y) = \frac{f_{xy}(x,y)}{f_x(x)}$$

Integrar sobre  $\Theta_y$   $f_x(x) = \int_{-\infty}^{\infty} f_{xy}(x,y) dy = \int_{-\infty}^{\infty} f_{x|y=y}(x) \cdot f_y(y) dy$

$$f_y(y) = \int_{-\infty}^{\infty} f_{xy}(x,y) dx = \int_{-\infty}^{\infty} f_{y|x=x}(y) \cdot f_x(x) dx$$

↑ Integrar Sobre  $\Theta_x$

## CASO MIXTO

X discreta, Y continua  
 $P_x(x) = \int_{-\infty}^{\infty} P_{x|y=y}(x) f_y(y) dy$

$$f_y(y) = \sum_{x \in \Theta_x} f_{y|x=x}(y) \cdot p_x(x)$$

## IMPORTANTE!!

En cualquiera de los casos, cuando se busca la marginal, integrar ó sumar sobre el dominio de la variable.

## CASO INDEPENDIENTE

Si X e Y son independientes

$$P_{xy}(x,y) = P_x(x) \cdot P_y(y)$$

$$f_{xy}(x,y) = f_x(x) \cdot f_y(y)$$

# FUNCIONES DE VARIABLES ALEATORIAS

$$Y = g(X) \leftrightarrow X = g^{-1}(Y)$$

(a) Si  $g^{-1}$  tiene raíz única:

CASO DISCRETO  $P(Y=y) = P(X=g^{-1}(y))$

$$\rightsquigarrow \text{Si } P(X=x) = a \rightarrow P(Y=g(x)) = a$$

$$\rightsquigarrow \text{Si } P(Y=y) = b \rightarrow P(X=g^{-1}(y)) = b$$

CASO CONTINUO  $\rightsquigarrow$  si conozco la distribución de  $x$ :

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{dg^{-1}(y)}{dy} \right| \quad \begin{array}{l} \text{"Jacobiano"} \\ \text{de la transformación} \end{array}$$

Para sacar la marginal de  $y$   
escribo la distribución  
de  $x$  "en función de  $y$ "

$\rightsquigarrow$  Si conozco la distribución de  $y$ :

$$f_X(x) = f_Y(g(x)) \left| \frac{dg(x)}{dx} \right|$$

CASO

ACUMULADO  $F_Y(y) = P(Y \leq y) = \begin{cases} P[X \leq g^{-1}(y)] & ; g(\cdot) \text{ creciente} \\ P[X \geq g^{-1}(y)] & ; g(\cdot) \text{ decreciente} \end{cases}$

(b) Si  $g^{-1}$  tiene múltiples soluciones:

$$Y = g(X) \rightarrow X = g^{-1}(Y) = x_1, x_2, \dots, x_k$$

$$\rightsquigarrow \text{Si } P(X=x_1) = a_1 \\ P(X=x_2) = a_2 \\ \vdots \\ P(X=x_k) = a_k \quad \left. \right\} P(Y=g(x_1) = g(x_2) = \dots = g(x_k)) = a_1 + a_2 + \dots + a_k$$

$\rightsquigarrow$  Si conozco la distribución de  $x$ :

$$P(Y=y) = \sum_{i=1}^k P(X_i = g^{-1}(y)) \text{ tal que } g(x_1) = g(x_2) = \dots = g(x_k) = y$$

CASO

DISCRETO  $P_Y(y) = \sum_{i=1}^k P_X(g_i^{-1}(y))$

CASO

CONTINUO  $f_Y(y) = \sum_{i=1}^k f_X(g_i^{-1}(y)) \left| \frac{d}{dy} g_i^{-1}(y) \right|$

# FUNCIONES DE MULTIPLES VARIABLES ALEATORIAS

$$Z = g(X, Y) \leftrightarrow P(Z = z) = P(g(X, Y) = z) \leftrightarrow X = g_1^{-1}(Y, Z)$$
$$Y = g_2^{-1}(X, Z)$$

CASO

DISCRETO  $P_Z(z) = \sum_{g(x,y)=z} P_{XY}(x,y)$

- cuando conozco  $P_X(x)$  y  $P_Y(y)$  y  $X, Y$  son INDEPENDIENTES:  
⇒ Despejo de  $g$  la que sea más fácil:  
 $y = h_1(z, x)$  ó  $x = h_2(z, y)$  (A PARTIR de  $g$ )  
luego,

$$P_Z(z) = \sum_{x \in \Theta_X} P_X(x) \cdot P_Y(x, z) \text{ ó } P_Z(z) = \sum_{y \in \Theta_Y} P_Y(y) \cdot P_X(y, z)$$

CASO

CONTINUO  $F_Z(z) = \int_{-\infty}^{\infty} \int_{-\infty}^z f_{XY}(g^{-1}(u), y) \left| \frac{d}{du} g^{-1} \right| du dy$  donde  $g^{-1} = g^{-1}(z, y)$

## SUMA DE V.A.

$$Z = X + Y \leftrightarrow x = z - y \leftrightarrow y = -x + z$$

$$\text{Jacobiano} = 1$$

CASO

DISCRETO  $P_Z(z) = \sum_{x \in \Theta_X} P_{XY}(x, z-x) = \sum_{y \in \Theta_Y} P_{XY}(z-y, y)$

⇒ si  $X$  e  $Y$  son independientes,

$$P_{XY} = P_X(x) \cdot P_Y(y)$$

## DIVISION

$$Z = XY \leftrightarrow x = \frac{z}{y}, \frac{\partial x}{\partial z} = \frac{1}{y} \leftrightarrow y = \frac{z}{x}, \frac{\partial y}{\partial z} = \frac{1}{x}$$

# FUNCIÓNES TÍPICAS

1. <sup>suma de</sup> Poisson Si  $X_i \sim \text{Poisson}(\lambda_i)$  INDEPENDIENTES

$$Z = \sum_i X_i \sim \text{Poisson}(\lambda_Z = \sum_i \lambda_i)$$

2. Suma de gammas Si  $X_i \sim \text{Gamma}(k_i, \nu)$  INDEPENDIENTES

$$Z = \sum_i X_i \sim \text{Gamma}\left(\sum_i k_i, \nu\right)$$

3. Suma de normales Si  $X_i \sim \text{Normal}(\mu_i, \sigma_i^2)$  INDEPENDIENTES

$$Z = \sum a_i X_i \sim \text{Normal}\left(\sum a_i \mu_i, \sqrt{\sum a_i^2 \sigma_i^2}\right)$$

4. Multiplicación de log-normales Si  $X_i \sim \text{log-normal}(\lambda_i, \sigma_i^2)$  INDEPENDIENTES

$$Z = \prod X_i^{a_i} \sim \text{log-normal}\left(\sum a_i \lambda_i, \sqrt{\sum a_i^2 \sigma_i^2}\right)$$

$$Y = \log(X_i) \sim \text{Normal}(\lambda_i, \sigma_i^2)$$

5. Normal al cuadrado Si  $X \sim \text{Normal}(0,1)$

$$CX^2 \sim \chi^2(1)$$

# DISTRIBUCIONES CONJUNTAS TÍPICAS

## Normal bivariada

$X = (X_1, \dots, X_n)$  es normal multivariada si

$$Y = a_1 X_1 + \dots + a_n X_n \sim \text{Normal}$$

→ Si  $X, Y$  distribuyen normal y son independientes,  $(X, Y)$  distribuye Normal-bivariada, pero si existe dependencia,  $(X, Y)$  no necesariamente distribuye normal-bivariada.

Si  $X \sim \text{Normal}(0, \sigma_x)$

$Y \sim \text{Normal}(0, \sigma_y)$

$$f_{XY}(x, y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\text{corr}(X,Y)^2}} \exp\left(-\frac{1}{2(1-\text{corr}(X,Y)^2)}\left(\frac{x^2}{\sigma_x^2} + \frac{y^2}{\sigma_y^2} - \frac{2xy\text{corr}(X,Y)}{\sigma_x\sigma_y}\right)\right)$$

## MEDIDAS DE TENDENCIA MULTIVARIABLES

• Esperanza:  $E(XY) = \iint_{\Omega_X \Omega_Y} xy \cdot f_{XY}(x, y) dx dy$

→ Si  $X$  e  $Y$  son independientes,  $E(XY) = E(X) \cdot E(Y)$

\* Si  $X$  e  $Y$  son independientes,  $f_{XY}(x, y) = f_X(x) \cdot f_Y(y)$

• Covarianza:  $\text{Cov}(XY) = E(XY) - E(X)E(Y)$

→ Si  $X$  e  $Y$  son independientes,  $\text{Cov}(XY) = 0$

• Correlación:  $\text{Corr}(XY) = \frac{\text{Cov}(XY)}{E(X) \cdot E(Y)}$  ;  $\text{Corr}(XY) \in (-1, 1)$

• Esperanza condicional:  $E(Y|X=x) = \sum_{y \in \Omega_Y | X=x} y \cdot P(Y=y | X=x)$   
$$\int_{y \in \Omega_Y | X=x} y \cdot f_{Y|X=x}(y) dy$$

• Esperanza iterada:  $E(Y) = E(E(Y|X))$