

# **EYP1113 - PROBABILIDAD Y ESTADÍSTICA**

LABORATORIO 5

PROFESORAS: NATALIA VENEGAS Y PILAR TELLO

FACULTAD DE MATEMÁTICAS

DEPARTAMENTO DE ESTADÍSTICA

PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

SEGUNDO SEMESTRE 2019

- 1 Medidas Descriptivas Teóricas vs Empíricas
  - Medidas Centrales
  - Medidas de Posición
  - Medidas de Dispersión
  - Medidas de Asimetría y Forma

# **MEDIDAS DESCRIPTIVAS TEÓRICAS VS EMPÍRICAS**

Una variable aleatoria puede ser descrita totalmente por su **función de distribución de probabilidad o de densidad**, o bien por su **función de distribución de probabilidad acumulada**.

Sin embargo, en la práctica la forma exacta puede no ser totalmente conocida.

En tales casos se requieren ciertas “medidas” para tener una idea de la forma de la distribución:

- Medidas Centrales.
- Medidas de Dispersión.
- Medidas de Asimetrías y Forma

## Valor esperado (media)

Para una variable aleatoria  $X$  se define el valor esperado,  $\mu_X$ , como:

$$\mu_X = E(X) = \begin{cases} \sum_{x \in \Theta_X} x \cdot p_X(x), & \text{Caso Discreto} \\ \int_{-\infty}^{\infty} x \cdot f_X(x) dx, & \text{Caso Continuo} \end{cases}$$

En **R**, la función **mean(, na.rm = TRUE)** la calcula de manera empírica.

Otras medidas de centro son:

- **La Moda:** Valor más frecuente o con mayor probabilidad.

```
filtro = (table(X) == max(table(X)))  
table(X)[filtro]
```

- **La Mediana:** Sea  $x_{\text{med}}$  el valor que toma la mediana, entonces:

$$F_X(x_{\text{med}}) = 1/2$$

En **R**, la función **median(, na.rm = TRUE)** la calcula de manera empírica.

## Esperanza matemática

La noción del valor esperado como un promedio ponderado puede ser generalizado para funciones de la variable aleatoria  $X$ .

Dada una función  $g(X)$ , entonces el valor esperado de esta puede ser obtenido como:

$$E[g(X)] = \begin{cases} \sum_{x \in \Theta_X} g(x) \cdot p_X(x), & \text{Caso Discreto} \\ \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx, & \text{Caso Continuo} \end{cases}$$

```
g = function(X){X^2}  
mean(g(X))
```

**Percentil:** Valor en los reales, llamemos  $x_p$ , que es superior al  $p \times 100$  % de la información.

$$F_X(x_p) = p$$

En **R** las siguientes funciones entregan percentiles empíricos.

"quantile"	: Percentil
"min"	: Mínimo
"max"	: Máximo



# MEDIDAS DESCRIPTIVAS TEÓRICAS VS EMPÍRICAS

## Varianza

$$\sigma_X^2 = \text{Var}(X) = E[(X - \mu_X)^2] = \begin{cases} \sum_{x \in \Theta_X} (x - \mu_X)^2 \cdot p_X(x), & \text{Caso Discreto} \\ \int_{-\infty}^{\infty} (x - \mu_X)^2 \cdot f_X(x) dx, & \text{Caso Continuo} \end{cases}$$

En **R**, la función **var()** la calcula.

**Rango:** Min - Max

$$\text{man}(X) - \text{min}(X)$$

**Rango Intercuantil:**  $X_{0,75} - X_{0,25}$

$$\text{IQR}(X) = \text{quantile}(X, 0.75) - \text{quantile}(X, 0.25)$$

# MEDIDAS DESCRIPTIVAS TEÓRICAS VS EMPÍRICAS

En términos de dimensionalidad, es conveniente utilizar la desviación estándar, es decir,

$$\sigma_X = \sqrt{\text{Var}(X)}$$

En **R**, la función **sd()** la calcula.

Ahora, si  $\mu_X > 0$ , una medida adimensional de la variabilidad es el coeficiente de variación (c.o.v)

$$\delta_X = \frac{\sigma_X}{\mu_X}$$

$$\delta = \text{sd}(X, \text{na.rm} = \text{TRUE}) / \text{mean}(X, \text{na.rm} = \text{TRUE})$$

# MEDIDAS DESCRIPTIVAS TEÓRICAS VS EMPÍRICAS

Se define una medida de asimetría (skewness) como al tercer momento central:

$$E[(X - \mu_X)^3] = \begin{cases} \sum_{x_i \in \Theta_X} (x_i - \mu_X)^3 \cdot p_X(x_i), & \text{Caso Discreto} \\ \int_{-\infty}^{\infty} (x - \mu_X)^3 \cdot f_X(x) dx, & \text{Caso Continuo} \end{cases}$$

Una medida conveniente es el coeficiente de asimetría que se define como:

$$\theta_X = \frac{E[(X - \mu_X)^3]}{\sigma_X^3}$$

# MEDIDAS DESCRIPTIVAS TEÓRICAS VS EMPÍRICAS

El cuarto momento central se conoce como la kurtosis

$$E[(X - \mu_X)^4] = \begin{cases} \sum_{x_i \in \Theta_X} (x_i - \mu_X)^4 \cdot p_X(x_i), & \text{Caso Discreto} \\ \int_{-\infty}^{\infty} (x - \mu_X)^4 \cdot f_X(x) dx, & \text{Caso Continuo} \end{cases}$$

que es una medida del “apuntamiento” o “achataamiento” de la distribución de probabilidad o de densidad.

Usualmente se prefiere el coeficiente de kurtosis

$$K_X = \frac{E[(X - \mu_X)^4]}{\sigma_X^4} - 3$$

# MEDIDAS DESCRIPTIVAS TEÓRICAS VS EMPÍRICAS

```
Skewness = function(x){  
  n = length(x)  
  sum((x - mean(x))^3/n)/sd(x)^3  
}
```

```
Kurtosis = function(x){  
  n = length(x)  
  sum((x - mean(x))^4/n)/sd(x)^4-3  
}
```

# MEDIDAS DESCRIPTIVAS TEÓRICAS VS EMPÍRICAS

Cuando hay dos variable aleatoria  $X$  e  $Y$ , puede haber una relación entre las variables.

En particular, la covarianza definida como

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E(X \cdot Y) - \mu_X \cdot \mu_Y$$

mide el grado de asociación lineal entre dos variables, pero es preferible su normalización llamada correlación para poder cuantificar la magnitud de la relación.

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y}$$

Este coeficiente toma valores en el intervalo  $(-1, 1)$ .

En **R**, las funciones **cov()** y **cor()** entrega ambas medidas.